

Aula 6 – Teórico

# Introdução dos Agentes de LLM



• **Agents Course** ⌵

Ctrl+K

EN ⌵

👤 27,491

- UNIT 0. WELCOME TO THE COURSE
- LIVE 1. HOW THE COURSE WORKS AND Q&A
- UNIT 1. INTRODUCTION TO AGENTS
- UNIT 2. FRAMEWORKS FOR AI AGENTS
- UNIT 2.1 THE SMOLAGENTS FRAMEWORK
- UNIT 2.2 THE LLAMAINDEX FRAMEWORK
- UNIT 2.3 THE LANGGRAPH FRAMEWORK
- UNIT 3. USE CASE FOR AGENTIC RAG
- UNIT 4. FINAL PROJECT - CREATE, TEST, AND CERTIFY YOUR AGENT
- BONUS UNIT 1. FINE-TUNING AN LLM FOR FUNCTION-CALLING
- BONUS UNIT 2. AGENT OBSERVABILITY AND EVALUATION
- BONUS UNIT 3. AGENTS IN GAMES WITH POKEMON

# Welcome to the 🤗 AI Agents Course

📄 Copy page ⌵



The background of the image was generated using [Scenario.com](#)

Welcome to the most exciting topic in AI today: **Agents**!

This free course will take you on a journey, **from beginner to expert**, in understanding, using and building AI agents.

This first unit will help you onboard:

- Discover the **course's syllabus**.

Welcome to the 🤗 AI Agents Course

- What to expect from this course?
- What does the course look like?
- What's the syllabus?
- What are the prerequisites?
- What tools do I need?
- The Certification Process
- What is the recommended pace?
- How to get the most out of the course?
- Who are we
- Acknowledgments
- I found a bug, or I want to improve the course
- I still have questions

O que é um  
Agente de  
LLM?



Olá!

HELLO  
MY NAME IS  
Alfred

**Alfred, eu gostaria  
de um café, por  
favor.**





Alfred's  
Toolbox

Reason and plan




**Execute**

**Seu café,  
senhor**

**Obrigado,  
Alfred**



# Definição



"Um **Agente** é tudo que pode **Perceber** seu ambiente por meio de **Sensores** e de **Agir** sobre esse ambiente por intermédio de **Atuadores**."

Alfred, eu gostaria de um café, por favor.



Select tools



Pedido do Usuário




Entende e Planeja



Executa o Planejamento

# O que é uma LLM?



| Modelo      | Parâmetros    |
|-------------|---------------|
| GPT-3       | 175 Bilhões   |
| PaLM 2      | 340 Bilhões   |
| DeepSeek V3 | 671 Bilhões   |
| GPT-4       | 1.76 Trilhões |


# Attention Is All You Need

|                                                                    |                                                                                     |                                                                  |                                                              |
|--------------------------------------------------------------------|-------------------------------------------------------------------------------------|------------------------------------------------------------------|--------------------------------------------------------------|
| <b>Ashish Vaswani*</b><br>Google Brain<br>avaswani@google.com      | <b>Noam Shazeer*</b><br>Google Brain<br>noam@google.com                             | <b>Niki Parmar*</b><br>Google Research<br>nikip@google.com       | <b>Jakob Uszkoreit*</b><br>Google Research<br>usz@google.com |
| <b>Llion Jones*</b><br>Google Research<br>llion@google.com         | <b>Aidan N. Gomez*<sup>†</sup></b><br>University of Toronto<br>aidan@cs.toronto.edu | <b>Lukasz Kaiser*</b><br>Google Brain<br>lukaszkaizer@google.com |                                                              |
| <b>Illia Polosukhin*<sup>‡</sup></b><br>illia.polosukhin@gmail.com |                                                                                     |                                                                  |                                                              |

## Abstract


The dominant sequence transduction models are based on complex recurrent or convolutional neural networks that include an encoder and a decoder. The best performing models also connect the encoder and decoder through an attention mechanism. We propose a new simple network architecture, the Transformer, based solely on attention mechanisms, dispensing with recurrence and convolutions entirely. Experiments on two machine translation tasks show these models to be superior in quality while being more parallelizable and requiring significantly less time to train. Our model achieves 28.4 BLEU on the WMT 2014 English-to-German translation task, improving over the existing best results, including ensembles, by over 2 BLEU. On the WMT 2014 English-to-French translation task, our model establishes a new single-model state-of-the-art BLEU score of 41.8 after training for 3.5 days on eight GPUs, a small fraction of the training costs of the best models from the literature. We show that the Transformer generalizes well to other tasks by applying it successfully to English constituency parsing both with large and limited training data.

# Autoregressivo



Crie um parágrafo resumindo quem é Gustavo Guanabara.  
Um dos maiores artistas e pescadores do Rio de Janeiro.


Gustavo Guanabara é reconhecido como uma figura multifacetada do Rio de Janeiro, destacando-se tanto no cenário artístico quanto na tradição da pesca. Conhecido por suas obras que capturam a essência da cultura carioca, ele combina sensibilidade criativa com uma forte conexão com o mar, sendo também admirado como um habilidoso pescador. Sua trajetória reflete uma vida equilibrada entre a expressão artística e a vivência prática, tornando-se uma personalidade respeitada em diferentes círculos da sociedade fluminense.



+ Pergunte alguma coisa




# Geração Aumentada por Recuperação (RAG)



- Fornecer o contexto necessário
- Aproveitamos que a LLM é boa em interpretar e gerar texto
- FAQ do produto, planilhas, sites da internet ou documentos.

# Ferramentas

"Um **Agente** é tudo que pode **Perceber** seu ambiente por meio de **Sensores** e de **Agir** sobre esse ambiente por intermédio de **Atuadores**."



Crie um parágrafo resumindo quem é Gustavo Guanabara.  
Um dos maiores artistas e pescadores do Rio de Janeiro.

Gustavo Guanabara é um professor e criador de conteúdo brasileiro conhecido por ensinar programação de forma acessível, sendo fundador do projeto Curso em Vídeo, que oferece cursos gratuitos na internet. Nascido no Rio de Janeiro, ele atua como educador desde a década de 1990 e se tornou uma das principais referências para iniciantes na área de tecnologia no Brasil, destacando-se pela didática simples e envolvente que já ajudou milhões de pessoas a dar os primeiros passos na programação Ponto Geek +1.

     ...  Fontes

Buscar na Web

  Buscar



Can you generate a picture of the Eiffel Tower made of broccoli?




Here's your image of the Eiffel Tower made entirely of broccoli! Let me know if you'd like any modifications. 🌱🍷




Agente na  
Prática



**Qual é o clima  
atual em Nova  
York?**






**O usuário precisa de informações climáticas atuais de Nova York.**

**Eu tenho acesso a uma ferramenta que busca dados sobre o clima. Primeiro, preciso chamar a API de clima para obter os detalhes atualizados.**

**Think Step**




```
{  
  "action": "get_weather",  
  "action_input": {  
    "location": "New York"  
  }  
}
```

**Act Step**



**Weather  
API**




**Clima atual em  
Nova York:  
parcialmente  
nublado, 15°C,  
60% de umidade.**

**Observation Step**




**Weather  
API**



**Agora que tenho os dados do  
clima de Nova York, posso  
compilar uma resposta para o  
usuário.**


**Think Step**




**O clima atual em Nova York é  
parcialmente nublado com  
uma temperatura de 15°C e  
60% de umidade.**



# ReAct





## 1. Configurando o Ambiente

Groq é uma plataforma de inferência de IA de alta performance. Ela oferece acesso via API a diversos modelos open-source de ponta.

Ela possui 2 atrativos principais. O primeiro é que ela oferece um plano gratuito que permite rodar LLMs poderosos de forma gratuita (dentro de certos limites de uso). O segundo é a velocidade de processamento, que é extremamente rápida.

Você pode [criar sua conta gratuitamente](#) e, após o login, gerar sua chave de API na aba "API Keys". Depois de se cadastrar, siga o seguinte passo a passo:

1. Acesse a aba Secrets (representada por um ícone de chave na barra lateral do Colab)
2. Clique em "**Adicionar novo secret**"
3. Defina o Nome `GROQ_API_KEY`
4. Cole a chave de API que você gerou na plataforma

```
[ ] 1 !pip install langchain-groq
```

## Configurando a LLM

```
[ ] 1 from langchain_groq import ChatGroq
2 from google.colab import userdata
3
4 llm = ChatGroq(
5     model="qwen/qwen3-32b",
6     api_key=userdata.get('GROQ_API_KEY'),
7     temperature=0.0,
8     reasoning_format="parsed"
9 )
```